



ELM - 472 Ödev 4
Makine Öğrenmesinin Temelleri
Dr. Öğr. Üyesi Ahmet Güneş

Hazırlayan:

Alican Bayındır

Elektronik Mühendisliği (Lisans)

20002002087

1) Aşağıda verilen denklem $p = 1, 2, 3$ değerleri için bir metrik midir? Regresyon problemi için $p = 1, 2, 3$ değerlerinden hangilerini ne tür problemler için kullanmayı tercih edebilirsiniz? Açıklayınız.

$$d(x_1, x_2) = \sqrt[p]{|x_1 - x_2|^p}$$

$d: X \times X \rightarrow \mathbb{R} \quad (x, y) \rightarrow d(x, y)$ fonksiyonu $x, y, z \in X$ olm.
üz.

(i) $d(x, y) > 0$

(ii) $d(x, y) = 0 \Leftrightarrow x = y$

(iii) $d(x, y) = d(y, x)$

(iv) $d(x, y) \leq d(x, z) + d(z, y) \rightarrow$ metrik fonksiyon (X, d) bir metrik uzaydır.

Bu aynı zamanda üçgen eşitsizliğidir.

Örneğin; (\mathbb{R}^2, d) metrik uzayını ele alalım

$$d((x_1, y_1), (x_2, y_2)) = |x_1 - x_2| + |y_1 - y_2|$$

her bir maddeyi sağlaması gerekir -metrik olması için-

$$d((x_1, y_1), (x_1, y_1)) = |x_1 - x_1| + |y_1 - y_1| = 0$$

$$0 = d((x_1, y_1), (x_2, y_2)) = |x_1 - x_2| + |y_1 - y_2|$$

İki değer de sıfır olması gerekir. Bundan dolayı da iki değer de birbirine eşit d'ye eşittir.

$$d((x_1, y_1), (x_2, y_2)) = |x_1 - x_2| + |y_1 - y_2| = |x_2 - x_1| + |y_2 - y_1| = d((x_2, y_2), (x_1, y_1))$$

$$\begin{aligned} d((x_1, y_1), (x_3, y_3)) + d((x_3, y_3), (x_2, y_2)) &= |x_1 - x_3| + |y_1 - y_3| + |x_3 - x_2| + |y_3 - y_2| \\ &= |x_1 - x_3| + |x_3 - x_2| + |y_1 - y_3| + |y_3 - y_2| \end{aligned}$$

üçgen eşitsizliği sağlanır.


$$\leq |x_1 - x_2| + |y_1 - y_2| = d((x_1, y_1), (x_2, y_2))$$

l_1 norm (Manhattan Distance)

Feature vector X


Alihan Bayındır
200102002087

(A)




$$l_1 \text{ norm: } \left(\sum_{i=1}^k |x_i| \right) = 5 + 1 = 6$$

l_2 norm (Euclidean Distance)



$$l_2 \text{ norm: } \left(\sum_{i=1}^k |x_i|^2 \right)^{\frac{1}{2}} = \sqrt{5^2 + 1^2} = \sqrt{26}$$


l_p norm (Generalized)



$$l_p \text{ norm: } \left(\sum_{i=1}^k |x_i|^p \right)^{\frac{1}{p}} = \sqrt[p]{5^p + 1^p} = \sqrt[p]{189} \rightarrow \text{Matematik kısmı doğru mu bilmiyorum}$$

Bonus

l_0 norm \rightarrow a.k.a "discrete metric" (not a norm) kaç eleman olduğunu sayılar



l_1 norm

l_2 norm

l_3 norm

l_∞ norm = $\max(x_1, x_2, \dots, x_k)$

Lasso regression Constraints

$$l_1 \text{ norm}(w) \leq r$$

Mean squared Error

$$\frac{1}{n} [l_2 \text{ norm}(y - \bar{y})]^2$$

Ridge Regression Constraint

$$l_2 \text{ norm}(w) \leq \sqrt{r}$$

$l_\infty \rightarrow$ worst case scenario

(3)

2) Aşağıda verilen Poisson olasılık dağılımının birinci ve ikinci momentini hesaplayınız.

4

$$P(x|\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots$$

$$\langle x^n \rangle = \sum_{x=0}^{\infty} x^n p(x)$$

$$\sum_{x=0}^{\infty} \frac{x \cdot e^{-\lambda} \lambda^x}{x(x-1)!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{(x-1)!} = \lambda e^{-\lambda} \left(\sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} \right)$$

$$= \lambda e^{-\lambda} \left(1 + \frac{\lambda}{1!} + \frac{\lambda^2}{2!} + \dots \right) = \lambda e^{-\lambda} e^{\lambda} = \boxed{\lambda}$$

when $n=2$

$$\langle x^2 \rangle = E(x^2) = \sum_{x=0}^{\infty} x^2 P(x) \Rightarrow \sum_{x=0}^{\infty} (x^2 - x + x) \frac{e^{-\lambda} \lambda^x}{x!}$$

$$\sum_{x=0}^{\infty} (x(x-1) + x) \frac{e^{-\lambda} \lambda^x}{x!} = \sum_{x=0}^{\infty} [x(x-1)] \frac{e^{-\lambda} \lambda^x}{x!} + \sum_{x=0}^{\infty} \frac{x e^{-\lambda} \lambda^x}{x!}$$

$$\sum_{x=2}^{\infty} \cancel{[x(x-1)]} \frac{e^{-\lambda} \lambda^x}{\cancel{x(x-1)}(x-2)!} + \sum_{x=0}^{\infty} \frac{x e^{-\lambda} \lambda^x}{x(x-1)!}$$

same eq. solved above it makes $\underline{\lambda}$

$$= e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^x}{(x-2)!} + \lambda = e^{-\lambda} \lambda^2 \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} + \lambda = \lambda^2 e^{-\lambda} e^{\lambda} + \lambda$$

$$\boxed{\langle x^2 \rangle = \lambda^2 + \lambda}$$

4

3) $\{[0.5, 0.5]^T, [0.5, 1.0]^T, [0.6, 0.5]^T\}$ örneklemini kullanarak en olası doğru denklemini bulunuz.

$$[a, b]^T = \begin{bmatrix} a \\ b \end{bmatrix}$$

	1	2	3
x_1	0.5	0.5	0.6
x_2	0.5	1	0.5

$$\frac{1.6}{3} = 0.53 = \bar{x}$$

$$0.66 = \bar{y}$$

$$y = w_1 x + w_0$$

$$w_1 = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{1.05 - 1.06}{0.86 - 1.3}$$

$$= \frac{0.01}{0.47} = 0.021 \text{ is the value of } w_1$$

$$w_0 = \bar{y} - w_1 \bar{x} \rightarrow 0.66 - 0.021 \cdot 0.53 = 0.648$$

$$\bar{y} = 0.648 + 0.021x$$